

机器学习

李成龙

安徽大学人工智能学院

“多模态认知计算”安徽省重点实验室

- 什么是机器学习
- **机器如何学习**
- 如何让机器学习的更好
- 为什么机器能学习

- 机器如何学习

- 有监督学习

- 感知机
 - 支持向量机
 - 朴素贝叶斯分类
 - 决策树
 - 集成学习（Bagging算法与随机森林、Boosting算法）
 - 线性回归
 - 逻辑回归
 - Softmax回归
 - 神经网络与深度学习

- 无监督学习

- 聚类
 - 主成分分析

- 概述
- 线性可分SVM与硬间隔最大化
- 线性SVM与软间隔最大化
- 非线性SVM与核函数

- 概述
- 线性可分SVM与硬间隔最大化
- 线性SVM与软间隔最大化
- 非线性SVM与核函数

1、感知机的分类超平面不唯一问题

- 增加约束，如SVM中的最大化间隔

2、感知机无法解决非线性问题

- 使用核方法，映射到高维空间

- 支持向量机(support vector machines. SVM)
 - 二分类模型
 - 基本模型是定义在特征空间上的间隔最大的线性分类器，间隔最大使它有别于感知机
 - 支持向量机还包括核技巧，这使它成为实质上的非线性分类器
 - 支持向量机的学习策略就是间隔最大化，可形式化为一个求解凸二次规划(convex quadratic programming)的问题，也等价于正则化的合页损失函数的最小化问题
 - 支持向量机的学习算法是求解凸二次规划的最优化算法


- 支持向量机

- 线性可分支持向量机(linear support vector machine in linearly separable case)
 - 硬间隔最大化(hard margin maximization)
- 线性支持向量机(linear support vector machine)
 - 训练数据近似线性可分时，通过软间隔最大化(soft margin maximization)
- 非线性支持向量机(non-linear support vector machine)
 - 当训练数据线性不可分时，通过使用核技巧(kernel trick)及软间隔最大化

- 概述
- 线性可分SVM与硬间隔最大化
- 线性SVM与软间隔最大化
- 非线性SVM与核函数


线性可分SVM与硬间隔最大化

- 线性模型：在样本空间中寻找一个超平面，将不同类别的样本分开



线性可分SVM与硬间隔最大化

- 将训练样本分开的超平面可能有很多，哪一个好呢？



• 函数间隔

- 超平面方程: $w^T x + b = 0$
- 样本数据点 x 到该超平面的距离表示为: $|w^T x + b|$
- 判断 $w^T x + b$ 与标记 y 符号是否一致
 - 若一致, 则分类正确; 否则, 分类错误
- 可用 $y(w^T x + b)$ 替代 $|w^T x + b|$ 表示样本数据点到超平面的距离
- **函数间隔**: $d_i = y_i(w^T x_i + b)$
- 样本数据集 D 的函数间隔 d 定义为 D 中所有样本数据点到超平面函数间隔的最小值, 即有: $d = \min d_i$
- d 作为优化指标构造SVM模型:

$$\max_{w, b} d, s.t. d_i \geq d$$

- 几何间隔

- 函数间隔的缺点：若同时同比例缩放其参数向量 \mathbf{w} 和偏置量 b ，会改变函数间隔 d_i 的取值

- 几何间隔

- 解决函数间隔 d_i 取值混乱的问题，对参数向量 \mathbf{w} 作归一化后计算得到的函数间隔
 - \hat{d}_i 为函数间隔 d_i 所对应的几何间隔，则有

$$\hat{d}_i = \frac{y_i(\mathbf{w}^T \mathbf{x}_i + b)}{\|\mathbf{w}\|} = \frac{d_i}{\|\mathbf{w}\|}$$

- 优化问题

$$\max_{\mathbf{w}, b} \hat{d} = \frac{d}{\|\mathbf{w}\|}, s.t. \hat{d}_i \geq \hat{d}$$

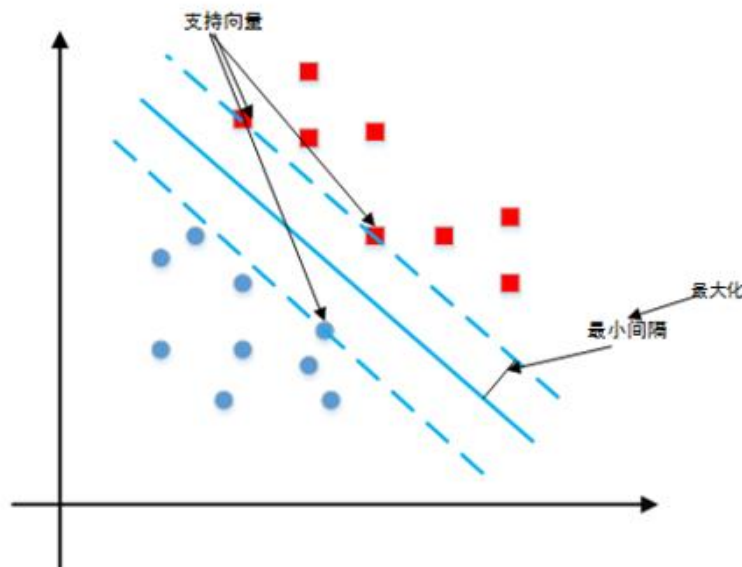
- 函数间隔

- 求得该优化问题的解 \mathbf{w}^* 和 b^* ，得到最优分离超平面：

$$\mathbf{w}^{*T} \mathbf{x} + b^* = 0$$

- SVM模型：

$$f(\mathbf{x}) = \text{sgn}(\mathbf{w}^{*T} \mathbf{x} + b^*)$$



- 几何间隔

- 函数间隔的缺点：若同时同比例缩放其参数向量 \mathbf{w} 和偏置量 b ，会改变函数间隔 d_i 的取值

- 几何间隔

- 可在对参数向量 \mathbf{w} 作归一化缩放基础上对其做进一步适当缩放，使得

$$d = 1$$


- 优化问题转化为

$$\max_{\mathbf{w}, b} \frac{1}{\|\mathbf{w}\|}, s.t. y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$$

线性可分SVM与硬间隔最大化



- 超平面方程: $w^\top x + b = 0$



- 支持向量机基本型：线性可分SVM

- 最大间隔：寻找参数 w 和 b , 使得 γ 最大

$$\max_{w,b} \frac{1}{\|w\|}$$

$$s.t. y_i(w^T x_i + b) \geq 1, i = 1, 2, \dots, n$$




$$\min_{w,b} \frac{1}{2} \|w\|^2$$

$$s.t. y_i(w^T x_i + b) - 1 \geq 0, i = 1, 2, \dots, n$$

- 凸二次规划问题(convex quadratic programming)

- 补充知识
 - 凸集

一个点集（或区域），如果连接其中任意两点 x_1, x_2 的线段都全部包含在该集合内，就称该点集为凸集，否则为非凸集



- 补充知识

- 凸性条件

- 根据一阶导数（函数的梯度）来判断函数的凸性

设 $f(x)$ 为定义在凸集 R 上，且具有连续的一阶导数的函数，则 $f(x)$ 在 R 上为凸函数的充要条件是对凸集 R 内任意不同两点 x_1, x_2 ，不等式 $f(x_2) \geq f(x_1) + (x_2 - x_1)^T \nabla f(x_1)$ 恒成立

- 根据二阶导数（Hessen矩阵）来判断函数的凸性

设 $f(x)$ 为定义在凸集 R 上且具有连续二阶导数的函数，则 $f(x)$ 在 R 上为凸函数的充要条件：Hessen矩阵在 R 上处处半正定

- 补充知识
 - 凸规划

对于约束优化问题

$$\begin{aligned} & \min f(x) \\ \text{s.t.} \quad & g_j(x) \leq 0 \quad j = 1, 2, \dots, m \end{aligned}$$

若 $f(x)$ 和 $g_j(x)$ 都为凸函数，则此问题为凸规划

- 补充知识

- 凸规划的性质

- 若给定一点 x_0 , 则集合 $R = \{x \mid f(x) \leq f(x_0)\}$ 为凸集
 - 可行域 $R = \{x \mid g_j(x) \leq 0, j = 1, 2, \dots, m\}$ 为凸集
 - 凸规划的任何局部最优解就是全局最优解

- 补充知识

- 凸优化问题

- 凸优化问题: 指约束最优化问题

$$\min_{\mathbf{w}} f(\mathbf{w}), s.t. g_i(\mathbf{w}) \leq 0, i = 1, 2, \dots, k, h_i(\mathbf{w}) = 0, i = 1, 2, \dots, l$$

其中, 目标函数 $f(\mathbf{w})$ 和约束函数 $g_i(\mathbf{w})$ 都是 R^n 上连续可微的凸函数, 约束函数 $h_j(\mathbf{w})$ 是 R^n 上的仿射函数

- 当目标函数为二次函数, g 函数为仿射函数时, 为凸二次规划问题

- 学习算法流程

- 输入：线性可分训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$

其中 $x \in \mathcal{X} \in R^n \quad y \in \mathcal{Y} \in \{-1, 1\}$

- 输出：最大间隔分离超平面和分类决策函数

- 构造并求解约束最优化问题，求得 w^* 和 b^*

$$\max_{w, b} \frac{1}{2} \|w\|^2$$

$$s.t. \quad y_i (w^T x_i + b) - 1 \geq 0, i = 1, 2, \dots, n$$

- 得到分离超平面

$$w^{*T} x + b^* = 0$$

- 分类决策函数

$$f(x_i) = \text{sgn}(w^{*T} x_i + b^*)$$

- 对偶问题

- 目标函数是二次的，约束条件是线性的，所以它是一个凸二次规划问题
- [QP \(Quadratic Programming\)](#) 的优化包都可以进行求解：在一定的约束条件下，目标最优，损失最小
- 结构特殊：通过 [Lagrange Duality](#) 变换到对偶变量 (dual variable) 的优化问题之后，可以找到一种更加有效的方法来进行求解
- 通常情况下这种方法比直接使用通用的 QP 优化包进行优化要**高效**得多
- 可以自然的引入**核函数**，进而推广到非线性分类问题

- 拉格朗日乘子法

- 引入拉格朗日乘子 $\alpha_i \geq 0$ 得到拉格朗日函数

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^m \alpha_i (y_i(\mathbf{w}^\top \mathbf{x}_i + b) - 1)$$

- 上式可以转换为

$$\min_{\mathbf{w}, b} \theta(\mathbf{w}) = \min_{\mathbf{w}, b} \max_{\alpha_i \geq 0} \mathcal{L}(\mathbf{w}, b, \boldsymbol{\alpha})$$

- 满足以下KKT条件时，上式等价于 $\max_{\alpha_i \geq 0} \min_{\mathbf{w}, b} \mathcal{L}(\mathbf{w}, b, \boldsymbol{\alpha})$

$$\begin{cases} \alpha_i \geq 0, \\ y_i f(\mathbf{x}_i) \geq 1, \\ \alpha_i (y_i f(\mathbf{x}_i) - 1) = 0. \end{cases}$$

- 拉格朗日乘子法

- 第一步：引入拉格朗日乘子 $\alpha_i \geq 0$ 得到拉格朗日函数

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^m \alpha_i (y_i(\mathbf{w}^\top \mathbf{x}_i + b) - 1)$$

- 第二步：令 $L(\mathbf{w}, b, \alpha)$ 对 \mathbf{w} 和 b 的偏导为零可得

$$\mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i, \quad \sum_{i=1}^m \alpha_i y_i = 0.$$

- 第三步：回代

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j - \sum_{i=1}^m \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \quad \alpha_i \geq 0, \quad i = 1, 2, \dots, m. \end{aligned}$$

- 使用序列最小化算法SMO求解，得到最优参数向量 α^* ，则

$$\mathbf{w}^* = \sum_{i=1}^m \alpha_i^* y_i \mathbf{x}_i; b_j^* = y_j - \sum_{i=1}^m \alpha_i^* y_i \mathbf{x}_i^T \mathbf{x}_j, \text{ where } \alpha_j \neq 0$$

其中，偏移项 b ：通过某个支持向量来确定

- 最终模型

$$f(\mathbf{x}_j) = \text{sgn}(\mathbf{w}^{*T} \mathbf{x}_j + b^*) = \text{sgn}\left(\sum_{i=1}^m \alpha_i^* y_i \mathbf{x}_i^T \mathbf{x}_j + b^*\right)$$

- KKT条件

$$\begin{cases} \alpha_i \geq 0, \\ y_i f(\mathbf{x}_i) \geq 1, \\ \alpha_i (y_i f(\mathbf{x}_i) - 1) = 0. \end{cases}$$

$$y_i f(\mathbf{x}_i) > 1 \quad \Rightarrow \quad \alpha_i = 0$$

支持向量机解的**稀疏性**: 训练完成后, 大部分的训练样本都不需保留, 最终模型仅与支持向量有关.

- 求解算法-SMO (Sequential Minimal Optimization)
 - 基本思路：不断执行如下两个步骤直至收敛
 - 第一步：选取一对需更新的变量 α_i 和 α_j
 - 第二步：固定 α_i 和 α_j 以外的参数，求解对偶问题更新 α_i 和 α_j
 - 仅考虑 α_i 和 α_j 时，对偶问题的约束变为

$$\alpha_i y_i + \alpha_j y_j = - \sum_{k \neq i, j} \alpha_k y_k, \quad \alpha_i \geq 0, \quad \alpha_j \geq 0.$$

用一个变量表示另一个变量, 回代入对偶问题可得一个单变量的二次规划, 该问题具有**闭式解**.

线性可分SVM与硬间隔最大化

- 练习：给定正例 $x_1=(3,3)$, $x_2=(4,3)$, 负例 $x_3=(1,1)$, 计算支持向量、分类决策函数和分类超平面方程

— 解：对偶形式

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \\ & = \frac{1}{2} (18\alpha_1^2 + 25\alpha_2^2 + 2\alpha_3^2 + 42\alpha_1\alpha_2 - 12\alpha_1\alpha_3 - 14\alpha_2\alpha_3) - \alpha_1 - \alpha_2 - \alpha_3 \\ \text{s.t.} \quad & \alpha_1 + \alpha_2 - \alpha_3 = 0 \\ & \alpha_i \geq 0, \quad i=1,2,3 \end{aligned}$$

把 $\alpha_3 = \alpha_1 + \alpha_2$ 代入目标函数，得到：

$$s(\alpha_1, \alpha_2) = 4\alpha_1^2 + \frac{13}{2}\alpha_2^2 + 10\alpha_1\alpha_2 - 2\alpha_1 - 2\alpha_2$$

对 α_1, α_2 求偏导，得到 (α_1, α_2) 在 $\left(\frac{3}{2}, -1\right)^T$ 取极值，但该点不满足约束条件 $\alpha_2 \geq 0$ ，所以最小值应在边界上达到

线性可分SVM与硬间隔最大化

- 练习：给定正例 $x_1=(3,3)$, $x_2=(4,3)$, 负例 $x_3=(1,1)$, 计算支持向量、分类决策函数和分类超平面方程

— 当 $\alpha_1=0$ 时, 最小值 $s\left(0, \frac{2}{13}\right) = -\frac{2}{13}$; 当 $\alpha_2=0$ 时, 最小值 $s\left(\frac{1}{4}, 0\right) = -\frac{1}{4}$

于是 $s(\alpha_1, \alpha_2)$ 在 $\alpha_1 = \frac{1}{4}, \alpha_2 = 0$ 获得极小, 则 $\alpha_3 = \alpha_1 + \alpha_2 = \frac{1}{4}$

$\alpha_1^* = \alpha_3^* = \frac{1}{4}$ 对应的实例向量为支持向量

计算得到: $w_1^* = w_2^* = \frac{1}{2}$

$$b^* = -2$$


分类决策函数为: $f(x) = \text{sign}\left(\frac{1}{2}x^{(1)} + \frac{1}{2}x^{(2)} - 2\right)$

分类超平面方程为: $\frac{1}{2}x^{(1)} + \frac{1}{2}x^{(2)} - 2 = 0$

- 概述
- 线性可分SVM与硬间隔最大化
- **线性SVM与软间隔最大化**
- 非线性SVM与核函数

线性SVM与软间隔最大化

- 训练数据中有一些特异点（outlier），不能满足函数间隔大于等于1的约束条件
- 引入“**软间隔**”的概念，允许支持向量机在一些样本上不满足约束



- 线性SVM模型

- 基本想法：最大化间隔的同时，让不满足约束的样本应尽可能少
- 引入一个松弛变量 ξ_i ，将约束条件转化为

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i$$

其中， ξ_i 的取值越大，模型对错误分类的容忍程度越高

- 线性SVM模型的目标函数

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i, s.t. y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, \xi_i \geq 0$$

其中 $C > 0$ 是为惩罚因子

- 软间隔最大化

- 上述优化问题对应的拉格朗日函数为

$$L(\mathbf{w}, b, \alpha, \xi, \mu) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i - \sum_{i=1}^m \alpha_i [y_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 + \xi_i] - \sum_{i=1}^m \mu_i \xi_i$$

- 即有


$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j - \sum_{i=1}^m \alpha_i, s.t. \sum_{i=1}^m \alpha_i y_i = 0, 0 \leq \alpha_i \leq C, \mu_i = C - \alpha_i$$

- 计算最优参数向量 α^* 后，可求得对应的软间隔支持向量机模型

$$f(\mathbf{x}_j) = \text{sgn}(\mathbf{w}^{*T} \mathbf{x}_j + b^*) = \text{sgn}\left(\sum_{i=1}^m \alpha_i^* y_i \mathbf{x}_i^T \mathbf{x}_j + b^*\right)$$

其中, $\mathbf{w}^* = \sum_{i=1}^m \alpha_i^* y_i \mathbf{x}_i$; $b_j^* = y_j - \sum_{i=1}^m \alpha_i^* y_i \mathbf{x}_i^T \mathbf{x}_j$, where $\alpha_j \neq 0, \xi_j = 0$

- 线性SVM的支持向量



- 线性SVM的另一种解释：合页损失函数

- 对于优化问题：

$$\min_{\mathbf{w}, b} \sum_{i=1}^m L(y_i(\mathbf{w}^T \mathbf{x}_i + b)) + \lambda \|\mathbf{w}\|^2$$

其中 L 称为合页损失函数，定义如下：

$$L(y(\mathbf{w}^T \mathbf{x} + b)) = [1 - y(\mathbf{w}^T \mathbf{x} + b)]_+, \quad [z]_+ = \begin{cases} z, & z > 0 \\ 0, & z \leq 0 \end{cases}$$

上述优化问题和线性SVM优化问题是等价的


$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i, \text{ s.t. } y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, \xi_i \geq 0$$

思考：如何证明等价性？

线性SVM与软间隔最大化



- 线性SVM的另一种解释：**合页损失函数**



- 概述
- 线性可分SVM与硬间隔最大化
- 线性SVM与软间隔最大化
- **非线性SVM与核函数**


- 线性不可分情况

- 若不存在一个能正确划分两类样本的超平面, 怎么办?
- 将样本从原始空间映射到一个更高维的特征空间, 使得样本在这个特征空间内线性可分

- 线性不可分情况

- 举个简单例子


- 线性分类面不存在
 - 从二维转换到三维: $x_3 = x_1 * x_2$



- 处理非线性数据

- 举个复杂例子

- 用两个半径不同的圆圈加上了少量的噪音生成得到如下数据



- 一个理想的分界应该是一个“圆圈”而不是一条线（超平面）

- 处理非线性数据



- 举个复杂例子

- 一条二次曲线（圆圈是二次曲线的一种特殊情况）的方程可以写作这样的形式

$$a_1X_1 + a_2X_1^2 + a_3X_2 + a_4X_2^2 + a_5X_1X_2 + a_6 = 0$$

- 构造另外一个五维的空间，其中五个坐标的值分别为 X_1 , X_1^2 , X_2 , X_2^2 , X_1X_2 , 那上述方程可以写成

$$\sum_{i=1}^5 a_i Z_i + a_6 = 0$$



• 处理非线性数据

- 维度的增大为计算带来了非常大的困难，而且如果遇到无穷维的情况，就根本无从计算了
- 例子：设两个向量 $x_1 = (\eta_1, \eta_2)^T$, $x_2 = (\xi_1, \xi_2)^T$, $\phi(\cdot)$ 表示之前2维到5维的映射，映射过后的内积是

$$\langle \phi(x_1), \phi(x_2) \rangle = \eta_1 \xi_1 + \eta_1^2 \xi_1^2 + \eta_2 \xi_2 + \eta_2^2 \xi_2^2 + \eta_1 \eta_2 \xi_1 \xi_2$$

又注意到： $\langle x_1, x_2 \rangle + 1 = \eta_1 \xi_1 + \eta_1^2 \xi_1^2 + \eta_2 \xi_2 + \eta_2^2 \xi_2^2 + \eta_1 \eta_2 \xi_1 \xi_2 + 1$

- 只要把某几个维度线性缩放一下，然后再加上一个常数维度，两者相等，区别是
 - 一个是映射到高维空间中，然后再根据内积的公式进行计算
 - 另一个则直接在原来的低维空间中进行计算，而不需要显式地写出映射后的结果
- 核函数： $\kappa(x_1, x_2) = (\langle x_1, x_2 \rangle + 1)^2$

- 核支持向量机

- 设样本 \mathbf{x} 映射后的向量为 $\phi(\mathbf{x})$, 划分超平面为

$$f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b$$

- 原始问题

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2$$

$$\text{s.t. } y_i(\mathbf{w}^\top \phi(\mathbf{x}_i) + b) \geq 1, \quad i = 1, 2, \dots, m.$$

- 对偶问题

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j) - \sum_{i=1}^m \alpha_i$$

只以内积的形式出现

$$\text{s.t. } \sum_{i=1}^m \alpha_i y_i = 0, \quad \alpha_i \geq 0, \quad i = 1, 2, \dots, m.$$

- 预测

$$f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b = \sum_{i=1}^m \alpha_i y_i \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}) + b$$

- 基本想法：不显式地设计核映射，而是设计**核函数**

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)$$

- Mercer定理(充分非必要)：只要一个对称函数所对应的核矩阵**半正定**，则它就能作为核函数来使用
- 常用核函数

| 名称 | 表达式 | 参数 |
|----------|--|--|
| 线性核 | $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^\top \mathbf{x}_j$ | |
| 多项式核 | $\kappa(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^\top \mathbf{x}_j)^d$ | $d \geq 1$ 为多项式的次数 |
| 高斯核 | $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ ^2}{2\delta^2}\right)$ | $\delta > 0$ 为高斯核的带宽(width) |
| 拉普拉斯核 | $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ }{\delta}\right)$ | $\delta > 0$ |
| Sigmoid核 | $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta \mathbf{x}_i^\top \mathbf{x}_j + \theta)$ | \tanh 为双曲正切函数, $\beta > 0, \theta < 0$ |

- 核函数的本质

- 实际中，我们会经常遇到线性不可分的样例，此时，我们的常用做法是把样例特征映射到高维空间中去
- 如果凡是遇到线性不可分的样例，一律映射到高维空间，那么这个维度大小是会高到可怕的
- 核函数的价值在于它虽然也是将特征进行从低维到高维的转换，但核函数的本质是在它事先在低维上进行计算，而将实质上的分类效果表现在了高维上，也就避免了直接在高维空间中的复杂计算

- **概述**
 - 解决了感知机遇到的两个关键问题
- **线性可分SVM与硬间隔最大化**
 - 函数间隔与几何间隔
 - SVM基本型
 - 对偶问题及其求解
- **线性SVM与软间隔最大化**
 - 特异点与软间隔
 - 线性SVM模型
- **非线性SVM与核函数**
 - 非线性问题
 - 核函数
 - 非线性SVM模型

- 线性可分SVM对噪声点敏感吗？为什么？
- 对于线性SVM通过引入软间隔的方式解决不满足约束条件的样本点，而非线性SVM能够处理这种情形吗？为什么？

- 推导线性SVM如下变形的对偶形式

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i^2, s.t. y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, \xi_i > 0$$